

# NOH-NMS: Improving Pedestrian Detection by Nearby Objects Hallucination

Tencent Youtu Lab(ACM MM 2020)

分享者：孙路

2024 年 1 月 3 日



- ① Introduction
- ② Related Work
- ③ Methodology
- ④ Experiments
- ⑤ A Further Step

- 1 Introduction
- 2 Related Work
- 3 Methodology
- 4 Experiments
- 5 A Further Step

# Introduction

- Non-maximum Suppression (NMS) 是一个经典的后处理算法；

# Introduction

- Non-maximum Suppression (NMS) 是一个经典的后处理算法；
- Greedy-NMS,  $N$  个 box, 处理复杂度  $\mathcal{O}(N^2)$ , 劣势在于对阈值敏感；

# Introduction

- Non-maximum Suppression (NMS) 是一个经典的后处理算法；
- Greedy-NMS,  $N$  个 box, 处理复杂度  $\mathcal{O}(N^2)$ , 劣势在于对阈值敏感；
- **NOH-NMS** 利用密度以及参数信息修正阈值, 从而达到更高的准确性；

# Introduction

- Non-maximum Suppression (NMS) 是一个经典的后处理算法；
- Greedy-NMS,  $N$  个 box, 处理复杂度  $\mathcal{O}(N^2)$ , 劣势在于对阈值敏感；
- NOH-NMS 利用密度以及参数信息修正阈值, 从而达到更高的准确性；
- CityPersons 以及 CrowdHuman 数据集上达到了 89%AP, 92.9%Recall。

## ① Introduction

## ② Related Work

Greedy-NMS

Soft-NMS

Adaptive-NMS

Fast NMS

Other work

## ③ Methodology

## ④ Experiments

## ⑤ A Further Step



## 1 Introduction

## 2 Related Work

Greedy-NMS

Soft-NMS

Adaptive-NMS

Fast NMS

Other work

## 3 Methodology

## 4 Experiments

## 5 A Further Step

# Greedy-NMS

最初的起点，基本原理是贪心，时间复杂度为  $\mathcal{O}(N^2)$ 。

```
input :  $\mathcal{B} = b_1, \dots, b_N, \mathcal{S} = s_1, \dots, s_N, N_t$   
       $\mathcal{B}$  is the list of initial detection boxes,  $\mathcal{S}$  contains corresponding  
      detection scores,  $N_t$  is the NMS threshold  
begin  
   $\mathcal{F} \leftarrow \{\}$ ;  
  while  $\mathcal{B} \neq \emptyset$  do  
     $m \leftarrow \arg \max \mathcal{S}$ ;  
     $\mathcal{M} \leftarrow b_m$ ;  
     $\mathcal{F} \leftarrow \mathcal{F} \cup \mathcal{M}; \mathcal{B} \leftarrow \mathcal{B} - \mathcal{M}$ ;  
    for  $b_i \in \mathcal{B}$  do  
      if  $\text{iou}(\mathcal{M}, b_i) \geq N_t$  then  
         $\mathcal{B} \leftarrow \mathcal{B} - b_i; \mathcal{S} \leftarrow \mathcal{S} - s_i$ ;  
      end  
    end  
  end  
  return  $\mathcal{F}, \mathcal{S}$   
end
```

## 1 Introduction

## 2 Related Work

Greedy-NMS

**Soft-NMS**

Adaptive-NMS

Fast NMS

Other work

## 3 Methodology

## 4 Experiments

## 5 A Further Step

# Soft-NMS

- Greedy-NMS 若 iou 大于阈值，则直接删去该框，容易将置信度高的临近框删去；

# Soft-NMS

- Greedy-NMS 若 iou 大于阈值，则直接删去该框，容易将置信度高的临近框删去；
- 剔除过程过程 Soft 一下；

# Soft-NMS

- Greedy-NMS 若 iou 大于阈值，则直接删去该框，容易将置信度高的临近框删去；
- 剔除过程过程 Soft 一下；
- 若 iou 大于阈值，改为乘上一个惩罚因子。

# Soft-NMS

- Greedy-NMS 若 iou 大于阈值，则直接删去该框，容易将置信度高的临近框删去；
- 剔除过程过程 Soft 一下；
- 若 iou 大于阈值，改为乘上一个惩罚因子。
- Soft-NMS – Improving Object Detection With One Line of Code (ICCV 2017)

# Soft-NMS

- Greedy-NMS 若 iou 大于阈值，则直接删去该框，容易将置信度高的临近框删去；
- 剔除过程过程 Soft 一下；
- 若 iou 大于阈值，改为乘上一个惩罚因子。
- Soft-NMS – Improving Object Detection With One Line of Code (ICCV 2017)



# Soft-NMS

- Greedy-NMS 若 iou 大于阈值，则直接删去该框，容易将置信度高的临近框删去；
- 剔除过程过程 Soft 一下；
- 若 iou 大于阈值，改为乘上一个惩罚因子。
- Soft-NMS – Improving Object Detection With One Line of Code (ICCV 2017)

Box<sub>*i*</sub> 的惩罚因子  $f(\mathcal{M}, b_i)$

$$f(\mathcal{M}, b_i) = \begin{cases} 1, & \text{iou}(\mathcal{M}, b_i) < N_t \\ 1 - \text{iou}(\mathcal{M}, b_i) \text{ or } \exp\left(\frac{-\text{iou}(\mathcal{M}, b_i)^2}{\sigma}\right), & \text{iou}(\mathcal{M}, b_i) \geq N_t \end{cases} \quad (1)$$

# Soft-NMS

每次至少删去一个 Box，时间复杂度仍为  $\mathcal{O}(N^2)$ ，但是运行效率大打折扣。

# Soft-NMS

每次至少删去一个 Box，时间复杂度仍为  $\mathcal{O}(N^2)$ ，但是运行效率大打折扣。

```
input :  $\mathcal{B} = b_1, \dots, b_N, \mathcal{S} = s_1, \dots, s_N, N_t$   
        $\mathcal{B}$  is the list of initial detection boxes,  $\mathcal{S}$  contains corresponding  
       detection scores,  $N_t$  is the NMS threshold  
begin  
   $\mathcal{F} \leftarrow \{\}$ ;  
  while  $\mathcal{B} \neq \emptyset$  do  
     $m \leftarrow \arg \max \mathcal{S}$ ;  
     $\mathcal{M} \leftarrow b_m$ ;  
     $\mathcal{F} \leftarrow \mathcal{F} \cup \mathcal{M}; \mathcal{B} \leftarrow \mathcal{B} - \mathcal{M}$ ;  
    for  $b_i \in \mathcal{B}$  do  
       $s_i \leftarrow s_i \cdot f(\mathcal{M}, b_i)$ ;  
    end  
  end  
  return  $\mathcal{F}, \mathcal{S}$   
end
```

## 1 Introduction

## 2 Related Work

Greedy-NMS

Soft-NMS

**Adaptive-NMS**

Fast NMS

Other work

## 3 Methodology

## 4 Experiments

## 5 A Further Step

# Adaptive-NMS

- 考虑到阈值在 NMS 算法中为定值，因此不能很好的处理不同的密度情况；

# Adaptive-NMS

- 考虑到阈值在 NMS 算法中为定值，因此不能很好的处理不同的密度情况；
- CNN solves everything;

# Adaptive-NMS

- 考虑到阈值在 NMS 算法中为定值，因此不能很好的处理不同的密度情况；
- CNN solves everything；
- 训练一个并行的网络去预测密度信息  $d_M$ ，不同的框根据密度设置不同的阈值；

# Adaptive-NMS

- 考虑到阈值在 NMS 算法中为定值，因此不能很好的处理不同的密度情况；
- CNN solves everything；
- 训练一个并行的网络去预测密度信息  $d_M$ ，不同的框根据密度设置不同的阈值；
- Adaptive NMS: Refining Pedestrian Detection in a Crowd(CVPR 2019)



# Adaptive-NMS

- 考虑到阈值在 NMS 算法中为定值，因此不能很好的处理不同的密度情况；
- CNN solves everything；
- 训练一个并行的网络去预测密度信息  $d_M$ ，不同的框根据密度设置不同的阈值；
- Adaptive NMS: Refining Pedestrian Detection in a Crowd(CVPR 2019)

# Adaptive-NMS

- 考虑到阈值在 NMS 算法中为定值，因此不能很好的处理不同的密度情况；
- CNN solves everything；
- 训练一个并行的网络去预测密度信息  $d_M$ ，不同的框根据密度设置不同的阈值；
- Adaptive NMS: Refining Pedestrian Detection in a Crowd(CVPR 2019)

$\mathcal{M}$  的阈值  $N_M$

$$N_M := \max(N_t, d_M) \quad (2)$$

# Adaptive-NMS




图 1: Adaptive-NMS 框架示意图

# Adaptive-NMS

**input** :  $\mathcal{B} = b_1, \dots, b_N, \mathcal{S} = s_1, \dots, s_N, \mathcal{D} = d_1, \dots, d_N, N_t$

$\mathcal{B}$  is the list of initial detection boxes,  $\mathcal{S}$  contains corresponding detection scores,  $\mathcal{D}$  contains corresponding detection densities,  $N_t$  is the NMS threshold

**begin**

$\mathcal{F} \leftarrow \{\};$

**while**  $\mathcal{B} \neq \emptyset$  **do**

$m \leftarrow \arg \max \mathcal{S};$

$\mathcal{M} \leftarrow b_m;$

$N_{\mathcal{M}} \leftarrow \max(N_t, d_m);$

$\mathcal{F} \leftarrow \mathcal{F} \cup \mathcal{M}; \mathcal{B} \leftarrow \mathcal{B} - \mathcal{M};$

**for**  $b_i \in \mathcal{B}$  **do**

**if**  $\text{iou}(\mathcal{M}, b_i) \geq N_{\mathcal{M}}$  **then**

$\mathcal{B} \leftarrow \mathcal{B} - b_i; \mathcal{S} \leftarrow \mathcal{S} - s_i;$

**end**

**end**

**end**

**return**  $\mathcal{F}, \mathcal{S}$

**end**

## 1 Introduction

## 2 Related Work

Greedy-NMS

Soft-NMS

Adaptive-NMS

**Fast NMS**

Other work

## 3 Methodology

## 4 Experiments

## 5 A Further Step

# Fast NMS

- NMS 太慢了，尤其是软处理系列的 NMS，由于几乎都是串行计算，算法常数很大；

# Fast NMS

- NMS 太慢了，尤其是软处理系列的 NMS，由于几乎都是串行计算，算法常数很大；
- 牺牲一些精度换取更快的实现；

# Fast NMS

- NMS 太慢了，尤其是软处理系列的 NMS，由于几乎都是串行计算，算法常数很大；
- 牺牲一些精度换取更快的实现；
- 会抑制更多的框，在密度大的情况下表现不好；



# Fast NMS

- NMS 太慢了，尤其是软处理系列的 NMS，由于几乎都是串行计算，算法常数很大；
- 牺牲一些精度换取更快的实现；
- 会抑制更多的框，在密度大的情况下表现不好；
- 时间复杂度瓶颈在于上三角矩阵的计算，这一步还是  $O(N^2)$ ；

# Fast NMS

- NMS 太慢了，尤其是软处理系列的 NMS，由于几乎都是串行计算，算法常数很大；
- 牺牲一些精度换取更快的实现；
- 会抑制更多的框，在密度大的情况下表现不好；
- 时间复杂度瓶颈在于上三角矩阵的计算，这一步还是  $O(N^2)$ ；
- YOLACT: Real-time Instance Segmentation(ICCV 2019)；

# Fast NMS

- NMS 太慢了，尤其是软处理系列的 NMS，由于几乎都是串行计算，算法常数很大；
- 牺牲一些精度换取更快的实现；
- 会抑制更多的框，在密度大的情况下表现不好；
- 时间复杂度瓶颈在于上三角矩阵的计算，这一步还是  $O(N^2)$ ；
- YOLACT: Real-time Instance Segmentation(ICCV 2019)；
- “In the Mask R-CNN benchmark suite , Fast NMS is 15.0 ms faster than their CUDA implementation of traditional NMS with a performance loss of only 0.3 mAP.”

# Fast NMS

```
input :  $\mathcal{B} = b_1, \dots, b_N, \mathcal{S} = s_1, \dots, s_N, N_t$   
         $\mathcal{B}$  is the list of initial detection boxes,  $\mathcal{S}$  contains corresponding  
        detection scores,  $N_t$  is the NMS threshold  
begin  
     $\mathcal{F} \leftarrow \{\}$ ;  
    Sort( $\mathcal{B}$ ) in descending order based on the key value  $\mathcal{S}$ ;  
     $\text{IoU}_{N \times N} \leftarrow \mathbf{0}$ ;  
    for  $i := 1$  to  $N$  do  
         $t \leftarrow 0$ ;  
        for  $j := 1$  to  $i - 1$  do  
             $t := \max(t, \text{iou}(b_i, b_j))$ ;  
        end  
        if  $t < N_t$  then  
             $\mathcal{F} \leftarrow \mathcal{F} \cup b_i$   
        end  
    end  
    return  $\mathcal{F}$   
end
```

## 1 Introduction

## 2 Related Work

Greedy-NMS

Soft-NMS

Adaptive-NMS

Fast NMS

Other work

## 3 Methodology

## 4 Experiments

## 5 A Further Step

## Other work

- Matrix NMS(SOLOv2: Dynamic and Fast Instance Segmentation, NeurIPS'20);

# Other work

- Matrix NMS(SOLOv2: Dynamic and Fast Instance Segmentation, NeurIPS'20);
- Cluster NMS(Enhancing Geometric Factors in Model Learning and Inference for Object Detection and Instance Segmentation, TCYB)

- 1 Introduction
- 2 Related Work
- 3 Methodology**
- 4 Experiments
- 5 A Further Step



# NOH-NMS Methodology

- 结合 Adaptive-NMS 和 Soft NMS 的优势;

# NOH-NMS Methodology

- 结合 Adaptive-NMS 和 Soft NMS 的优势；
- 密度大的时候不选用脉冲函数，而是乘以一个高斯分布。

# NOH-NMS Methodology

- 结合 Adaptive-NMS 和 Soft NMS 的优势；
- 密度大的时候不选用脉冲函数，而是乘以一个高斯分布。

# NOH-NMS Methodology

- 结合 Adaptive-NMS 和 Soft NMS 的优势；
- 密度大的时候不选用脉冲函数，而是乘以一个高斯分布。

NOH 惩罚因子  $f(\mathcal{M}, b_i, d_{\mathcal{M}}, p_{\mathcal{M}})$

$$f(\mathcal{M}, b_i, d_{\mathcal{M}}, p_{\mathcal{M}}) = \begin{cases} P_{PM}(\mathcal{M}, b_i), & d_{\mathcal{M}} \geq d_t \\ 0, & d_{\mathcal{M}} < d_t \end{cases} \quad (3)$$

# NOH-NMS Methodology

- 结合 Adaptive-NMS 和 Soft NMS 的优势;
- 密度大的时候不选用脉冲函数, 而是乘以一个高斯分布。

NOH 惩罚因子  $f(\mathcal{M}, b_i, d_{\mathcal{M}}, p_{\mathcal{M}})$

$$f(\mathcal{M}, b_i, d_{\mathcal{M}}, p_{\mathcal{M}}) = \begin{cases} P_{PM}(\mathcal{M}, b_i), & d_{\mathcal{M}} \geq d_t \\ 0, & d_{\mathcal{M}} < d_t \end{cases} \quad (3)$$

其中  $d_t$  是一个超参数, 文中设置成 0.3。

# Nearby Object Hallucinator

- Nearby Object Hallucinators 也是一个并行的计算密度的 CNN 网络;

# Nearby Object Hallucinator

- Nearby Object Hallucinators 也是一个并行的计算密度的 CNN 网络;
- 同时它会预测出一些 hallucination;

# Nearby Object Hallucinator

- Nearby Object Hallucinators 也是一个并行的计算密度的 CNN 网络;
- 同时它会预测出一些 hallucination;
- 考虑到  $\mathcal{M}$  时, 只考虑重叠最多的幻觉框, 参数记为  $\mu_{\mathcal{M}}$ 。



# Nearby Object Hallucinator

- Nearby Object Hallucinators 也是一个并行的计算密度的 CNN 网络;
- 同时它会预测出一些 hallucination;
- 考虑到  $\mathcal{M}$  时, 只考虑重叠最多的幻觉框, 参数记为  $\mu_{\mathcal{M}}$ 。

# Nearby Object Hallucinator

- Nearby Object Hallucinators 也是一个并行的计算密度的 CNN 网络;
- 同时它会预测出一些 hallucination;
- 考虑到  $\mathcal{M}$  时, 只考虑重叠最多的幻觉框, 参数记为  $\mu_{\mathcal{M}}$ 。

## 分布参数 $P$

$$P_{\mu_{\mathcal{M}}}(\mathcal{M}, b_i) = \exp(-\|b_i|_{\mathcal{M}} - \mu_{\mathcal{M}}\|^2/2\sigma^2) \quad (4)$$

# Nearby Object Hallucinator

- Nearby Object Hallucinators 也是一个并行的计算密度的 CNN 网络;
- 同时它会预测出一些 hallucination;
- 考虑到  $\mathcal{M}$  时, 只考虑重叠最多的幻觉框, 参数记为  $\mu_{\mathcal{M}}$ 。

## 分布参数 $P$

$$P_{\mu_{\mathcal{M}}}(\mathcal{M}, b_i) = \exp(-\|b_{i|\mathcal{M}} - \mu_{\mathcal{M}}\|^2 / 2\sigma^2) \quad (4)$$

其中:

$$b_{i|\mathcal{M}} = \left\{ \frac{x_{b_i} - x_{\mathcal{M}}}{w_{\mathcal{M}}}, \frac{y_{b_i} - y_{\mathcal{M}}}{h_{\mathcal{M}}}, \log \frac{w_{b_i}}{w_{\mathcal{M}}}, \log \frac{h_{b_i}}{h_{\mathcal{M}}} \right\} \quad (5)$$

# NOH-NMS 框架




图 2: NOH-NMS 框架示意图

# NOH-NMS Algorithm

```
input :  $\mathcal{B} = b_1, \dots, b_N, \mathcal{S} = s_1, \dots, s_N, \mathcal{D} = d_1, \dots, d_N, \mathcal{P} = p_1, \dots, p_N, N_t$   
         $\mathcal{B}$  is the list of initial detection boxes,  $\mathcal{S}$  contains corresponding  
detection scores,  $\mathcal{D}$  contains corresponding detection densities,  $\mathcal{P}$  contains the  
parameters of nearby-objects distribution of corresponding detection,  $N_t$  is the  
NMS threshold  
begin  
     $\mathcal{F} \leftarrow \{\};$   
    while  $\mathcal{B} \neq \emptyset$  do  
         $m \leftarrow \arg \max \mathcal{S};$   
         $\mathcal{M} \leftarrow b_m;$   
         $\mathcal{F} \leftarrow \mathcal{F} \cup \mathcal{M}; \mathcal{B} \leftarrow \mathcal{B} - \mathcal{M};$   
        for  $b_i \in \mathcal{B}$  do  
            if  $\text{iou}(\mathcal{M}, b_i) \geq N_t$  then  
                 $s_i \leftarrow s_i \cdot f(\mathcal{M}, b_i, d_{\mathcal{M}}, p_{\mathcal{M}});$   
            end  
        end  
    end  
    return  $\mathcal{F}, \mathcal{S}$   
end
```

- 1 Introduction
- 2 Related Work
- 3 Methodology
- 4 Experiments**
- 5 A Further Step

# Implementation Details

- baseline: Faster-RCNN with FPN;

---

<sup>1</sup>Citypersons: A diverse dataset for pedestrian detection (CVPR 2017)

<sup>2</sup>Crowdhuman: A benchmark for detecting human in a crowd(arXiv preprint arXiv:1805.00123 )

# Implementation Details

- baseline: Faster-RCNN with FPN;
- datasets: CityPersons<sup>1</sup> 以及 CrowdHuman<sup>2</sup>

---

<sup>1</sup>Citypersons: A diverse dataset for pedestrian detection (CVPR 2017)

<sup>2</sup>Crowdhuman: A benchmark for detecting human in a crowd(arXiv preprint arXiv:1805.00123 )



# Implementation Details

- baseline: Faster-RCNN with FPN;
- datasets: CityPersons<sup>1</sup> 以及 CrowdHuman<sup>2</sup>
- ResNet-50 as the backbone and replace the ROI Pooling operation in the original Faster-RCNN with the RoIAlign.

---

<sup>1</sup>Citypersons: A diverse dataset for pedestrian detection (CVPR 2017)

<sup>2</sup>Crowdhuman: A benchmark for detecting human in a crowd(arXiv preprint arXiv:1805.00123 )

# Results

Methods	Extra Anno.	Backbone	Scale	Reasonable	Bare	Partial	Heavy
OR-CNN [35]	✓	VGG-16	×1.3	11.0	<b>5.9</b>	<b>13.7</b>	51.3
MGAN [22]	✓	VGG-16	×1.3	10.5	-	-	<b>47.2</b>
JointDet [3]	✓	ResNet-50	×1.3	<b>10.2</b>	-	-	-
TLL (MRF) [29]		ResNet-50	-	14.4	-	-	-
Adapted Faster RCNN [34]		VGG-16	×1.3	13.0	-	-	-
ALFNet [21]		VGG-16	×1	12.0	8.4	11.4	<b>51.9</b>
RepLoss [31]		ResNet-50	×1.3	11.6	7.0	14.8	55.3
Adaptive-NMS w/ AggLoss [18]		VGG-16	×1.3	<b>10.8</b>	<b>6.2</b>	11.4	54.0
Our baseline		ResNet-50	×1.3	11.9	7.4	12.3	53.0
NOH-NMS		ResNet-50	×1.3	<b>10.8</b>	6.6	<b>11.2</b>	53.0

**Table 1: Performance on the CityPersons validation set.** MR<sup>-2</sup> is used as the metric (lower is better). Scale is short for input scale.

# Results

Methods	$N_t$	AP	Recall	$MR^{-2}$
Greedy-NMS	0.5	85.1	87.8	44.7
Soft-NMS [1]	0.5	86.4	90.6	44.6
Adaptive-NMS [18]	0.5	87.1	89.2	45.0
NOH-NMS	0.5	<b>89.0</b>	<b>92.9</b>	<b>43.9</b>

**Table 3: Comparison of different NMS methods on the CrowdHuman validation set.** All the methods are implemented by us, and for fair comparisons, we show the best results from multiple runs.

- 1 Introduction
- 2 Related Work
- 3 Methodology
- 4 Experiments
- 5 A Further Step**

# A Further Step

- NMS 在 YOLO v8 中的处理时间已经成为了瓶颈，过去的工作大多数是以提升准确率为目标，鲜有优化复杂度的工作；

# A Further Step

- NMS 在 YOLO v8 中的处理时间已经成为了瓶颈，过去的工作大多数是以提升准确率为目标，鲜有优化复杂度的工作；
- Fast NMS 提供了一些思路，但是由于其需要计算 IoU 矩阵，复杂度仍为  $\mathcal{O}(N^2)$ ；

# A Further Step

- NMS 在 YOLO v8 中的处理时间已经成为了瓶颈，过去的工作大多数是以提升准确率为目标，鲜有优化复杂度的工作；
- Fast NMS 提供了一些思路，但是由于其需要计算 IoU 矩阵，复杂度仍为  $\mathcal{O}(N^2)$ ；
- 本质是计算最大的前缀 iou 值；

## A Further Step

- NMS 在 YOLO v8 中的处理时间已经成为了瓶颈，过去的工作大多数是以提升准确率为目标，鲜有优化复杂度的工作；
- Fast NMS 提供了一些思路，但是由于其需要计算 IoU 矩阵，复杂度仍为  $\mathcal{O}(N^2)$ ；
- 本质是计算最大的前缀 iou 值；
- 简化问题为询问中心点  $k$  近邻的矩形，online KD-Tree 或者基于随机的平面分割算法可以在  $\mathcal{O}(k \log^r(N))$  的复杂度内查询。



Thanks!